

機器學習基礎數學 — 機率與統計應用

機器學習的核心在於處理資料中的不確定性，透過機率與統計方法推論與建構模型。

1. 機率與統計在機器學習中的角色

- 資料中存在取樣變異與內在隨機性，導致預測結果不具唯一性。
 - 機器學習模型學習的是條件機率分佈 $P(Y|X)$ ，非確定性結果。
 - 機率能反映模型對預測的信心，幫助風險控制與決策。
2. 資料與隨機變數的機率表示

類型	說明	表示方式	範例
離散型	隨機變數值為有限或可數，如擲骰子結果、訂單數量	機率質量函數 (Probability Mass Function, PMF)	伯努利分佈、二項分佈、泊松分佈
連續型	隨機變數值為無限且連續，如身高、體重、時間	機率密度函數 (Probability Density Function, PDF)	常態分佈、指數分佈、卡方分佈

離散型機率分佈重點

- PMF 表示隨機變數每個特定取值的機率， $\sum P(X = x_i) = 1$ 。
- 伯努利分佈：兩種可能結果（成功/失敗），常用於二元分佈。
- 二項分佈：n 次獨立試驗中事件發生的次數。
- 泊松分佈：固定時間或空間區間內事件發生次數，具獨立且平均發生率固定特性。

連續型機率分佈重點

- PDF 用於描述連續變數在區間內的機率， $P(a \leq X \leq b) = \int_a^b f(x)dx$ 。
- 常態分佈：對稱鐘型，廣泛用於誤差建模與參數估計。
- 均勻分佈：區間內所有數值機率相同，用於參數初始化等。
- 指數分佈：描述事件間隔時間，具無記憶性。
- 卡方分佈：獨立標準常態平方和分佈，用於統計推定。

3. 條件機率與貝氏推論

條件機率 $P(A|B)$ 表示在事件 B 已發生條件下，事件 A 發生的機率。

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

- 在機器學習中，如分類模型即學習 $P(Y|X)$ 。
- 應用範例：
 - 分類任務預測目標標籤機率。
 - 生醫與金融風控的風險預測。
 - 生成模型中潛在變數與觀察變數的依存關係。

貝氏定理 (Bayes' Theorem)

利用已知條件和先驗知識，更新事件機率的公式：

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

符號	解釋	
$P(A)$	先驗機率 (Prior)：事件 A 發生的初始信念	
$P(B A)$	似然 (Likelihood)：事件 A 發生下， B 發生的機率	
$P(B)$	邊際機率 (Marginal)：事件 B 發生的總體機率	
$P(A B)$	後驗機率 (Posterior)：觀察到 B 後，更新的 A 發生機率	

- 貝氏定理核心在於結合原有知識與新資料，提升模型對不確定性與資料稀疏的推論能力。

4. 假設檢定與統計推論

統計推論 (Statistical Inference) 根據有限樣本，推論母體參數或模型行為，量化不確定性。

分支	目的	重點問題	輸出結果	例子
參數估計	推測母體參數的值或區間	母體參數的大約值 (如平均值)	點估計值與信賴區間 (例如 95% 信賴區間)	平均體重估計為 68 公斤，95% CI 為 [66, 70]
假設檢定	驗證關於母體參數的假設是否成立	是否有足夠證據拒絕絕某假設	p 值與檢定統計量，決定是否拒絕虛無假設	新運動課程能降低體重， $p=0.03 < 0.05$ 拒絕虛無假設

假設檢定流程

- 設定虛無假設 (H_0) 與對立假設 (H_1)
- 選擇適當檢定方法及統計量
- 決定顯著水準 α
- 計算檢定統計量與 p 值
- 根據 α 決定是否拒絕虛無假設

顯著水準 (α) 與 p 值

名稱	定義
顯著水準 α	預設錯誤拒絕虛無假設的最大容許機率 (型一錯誤)
p 值	根據樣本資料計算的機率，衡量數據與虛無假設相符程度

- 若 $p < \alpha$ ，表示有足夠證據拒絕虛無假設。

5. 統計量在機器學習中的應用

統計量	功能與應用
期望值 (Expected Value)	反映變數平均趨勢，模型預測基準與參數估計核心
變異數 (Variance) 與標準差 (Standard Deviation)	衡量資料離散程度，判斷是否需標準化，避免訓練偏誤
偏態 (Skewness)	判斷資料分佈是否對稱，偏態大時需進行轉換改善模型收斂性
峰度 (Kurtosis)	觀察資料尖峰或厚尾特性，偵測異常值密度與風險指數

- 統計量常用視覺化工具輔助理解，如直方圖、箱型圖、QQ-plot。

- 協助資料探索、特徵工程、模型訓練與效能評估。

線性代數之機器學習基礎應用

線性代數是機器學習模型運算的數學基礎，涵蓋資料表示、參數計算、梯度更新與特徵轉換。

1. 線性代數在機器學習中的重要性

- 機器學習演算法多以向量 (Vector) 與矩陣 (Matrix) 作為運算單位。
- 線性變換、特徵分解、最小平方估計等工具支撐模型訓練與預測。
- 理解幾何意義有助於掌握演算法內部機制。

資料結構	說明	例子
向量	具有方向與大小的數學物件，表示單一特徵組合	$x = [x_1, x_2, x_3, x_4, x_5]$ 表示五維特徵向量
矩陣	多行多列的數值集合，表示多筆樣本或多組特徵	用於同時表達多筆資料、模型參數矩陣

- 向量與矩陣是機器學習中資料儲存與運算的基礎。
- 支持特徵表達、線性組合、梯度計算等核心步驟。

以上內容涵蓋機器學習基礎數學的機率與統計及線性代數應用，為後續模型設計、訓練與評估奠定重要理論基礎。

向量與矩陣在機器學習中的基礎運算與應用

向量與矩陣是機器學習中資料與模型運算的核心結構，其運算涵蓋點積、範數、矩陣乘法等，支撐模型預測、特徵轉換與參數更新。

運算類型	定義與意義	應用範例
點積 (Dot Product)	評估兩向量同方向上的對應程度，物理意義為「投影」與「相似性」，線性模型預測的核心。	線性模型預測： $Y = \theta^T x$
L2 範數 (Norm)	又稱歐幾里得範數，用於計算向量長度或大小，是正規化與正則化的基礎。	計算誤差向量、梯度向量長度
向量加減與線性組合	用於計算誤差向量、梯度向量等，是模型參數調整的重要運算。	梯度更新、誤差反向傳播

矩陣的基本應用與運算

矩陣種類	符號與維度	用途說明
特徵矩陣	$X \in \mathbb{R}^{n \times d}$	n 筆樣本、每筆 d 個特徵，行代表樣本向量。
權重矩陣	$W \in \mathbb{R}^{d \times k}$	多類別分類中，將 d 維輸入特徵映射為 k 維輸出機率分數。
矩陣運算	定義與意義	應用範例
矩陣乘法	核心運算，用於批次預測、權重更新及特徵空間轉換。	線性迴歸預測： $y = X\theta$ ；神經網路前向傳播： $z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)}$
轉置 (Transpose)	將矩陣的行列互換，用於維度對齊與內積計算。	特徵空間變換、計算內積
矩陣求逆與偽逆	求解封閉解 (最小平方解) 或在不可逆矩陣時的近似解決方案。	最小平方估計的解析解

線性變換與特徵空間的幾何意義

線性變換保持空間的線性結構，包含縮放、旋轉、剪切及投影等操作，機器學習中多用於特徵映射與降維。

線性變換類型	幾何意義	說明與例子
縮放 (Scaling)	改變向量長度，不改變方向。	放大或縮小特徵向量的值。
旋轉 (Rotation)	改變向量方向，不改變長度。	正交變換或特徵對齊。
剪切 (Shearing)	改變向量方向，使其在空間中傾斜。	非對角矩陣的變換。
投影 (Projection)	將高維向量投影到子空間，保留對任務最有意義的資訊。	主成分分析 (PCA) 中的特徵空間投影。

特徵空間重構的主要功能

目標	方法說明	應用實例
特徵重組	將原始特徵線性組合產生新表示	PCA 透過正交基底重新組合特徵
維度轉換	將資料從高維轉換至低維或嵌入特徵空間	投影至主成分空間、隱藏層表示
方向加權	強化模型對特定方向的敏感度	調整模型參數影響特定特徵的影響

矩陣分解與維度簡化技術

矩陣分解透過將高維矩陣拆解為結構明確的子矩陣，有效壓縮資料、揭示潛在結構，提升模型效率與解釋性。

矩陣分解方法	原理與表示	幾何意義與應用
特徵值分解 (Eigenvalue Decomposition)	適用對稱方陣，將矩陣 $A \in \mathbb{R}^{n \times n}$ 分解為 $A = Q\Lambda Q^T$ ，其中 Q 為特徵向量矩陣， Λ 為特徵值對角矩陣。	找出資料空間中的「拉伸方向」基底，應用於 PCA、LDA 等降維與分類。

矩陣分解方法	原理與表示	幾何意義與應用
奇異值分解 (Singular Value Decomposition, SVD)	任意矩陣 $X \in \mathbb{R}^{m \times n}$ 可分解為 $X = U\Sigma V^T$ ， U 為左奇異向量， Σ 為奇異值對角矩陣， V 為右奇異向量。	將資料轉換為旋轉與縮放操作，應用於資料降維、推薦系統、語意分析與影像壓縮。
非負矩陣分解 (Non-negative Matrix Factorization, NMF)	將非負矩陣 $X \geq 0$ 分解為兩非負矩陣乘積 $X \approx WH$ ，其中 $W, H \geq 0$ 。	將資料視為可加部件，增強語意解釋力，應用於主題建模、影像與社群分析。

維度簡化的效益

效益	說明
提升訓練效率	降低模型參數數量與計算成本，特別適合大型資料集與深度學習模型。
穩定模型表現	去除雜訊與共線性，降低過擬合風險，提升準確度。
強化資料解釋性	轉換後特徵具明確幾何或語意意義，便於診斷及結果溝通。
利於視覺化分析	降維後可投影至二維或三維空間，方便資料探索與異常偵測。

最小平方估計與線性迴歸

線性迴歸模型透過最小平方估計 (Ordinary Least Squares, OLS) 找到最佳擬合線，最小化預測值與實際觀測值的平方誤差。

主要概念	說明
最小平方估計	參數估計方法，目標是使預測誤差平方和最小，提供穩定且具代表性的模型。
幾何視角	線性迴歸即為將資料點投影到最接近實際結果的平面，該平面即模型學習的線性關係。

線性迴歸的典型應用場景

應用領域	說明
銷售預測	根據廣告支出等預測未來營收。
醫療風險評估	利用年齡、血壓等指標預測患病概率或醫療費用。
房價估值	以房屋大小、樓層及地點等特徵預測合理價格。
行為建模	分析變數如何被多個條件共同影響。

數值優化技術與方法

機器學習模型訓練本質是數值優化問題，目標透過調整參數使損失函數 (Loss Function) 達到最小值，以提升模型表現。

最優化問題的組成要素

組成要素	定義與說明
目標函數 (Objective Function)	衡量模型輸出與實際答案偏差的函數，亦稱損失函數或成本函數。透過最小化該函數達成學習目標。
決策變數 (Decision Variables)	模型中需調整的參數，如線性模型的權重與偏差、神經網路的連接權重等。
可行域 (Feasible Region)	決策變數的合法範圍，包含非負限制、上下限、線性和約束與稀疏性限制，確保參數合理且模型穩定。
函數性質 (凸性與可導性)	凸性保證全局最優解可達成；可導性允許使用梯度進行有效參數更新。非凸問題 (如深度學習) 存在局部最小值與鞍點。

常見目標函數類型與對應任務

任務類型	目標函數範例	功能與特點
迴歸任務	均方誤差 (MSE)、平均絕對誤差 (MAE)、Huber 損失	MSE 放大大誤差貢獻，MAE 對異常值不敏感，Huber 結合兩者優點。
分類任務	交叉熵損失 (Cross-Entropy Loss)、對比損失 (Contrastive Loss)、Focal Loss	交叉熵適合多類別分類，對比損失學習相似度高、Focal Loss 強化難分類樣本學習。
排序與重建	排序損失 (Ranking Loss)、重建損失	排序損失關注資料相對順序，重建損失應用於自編碼器與生成模型。

優化演算法與技術比較

演算法類型	主要特點與機制	適用場景與限制
梯度下降法 (GD)	使用全部訓練資料計算梯度，更準確，計算成本高昂且訓練速度慢。	適合小型資料集與高精度需求。
隨機梯度下降 (SGD)	每次以單一樣本估算梯度，更新快速但波動大，收斂不穩定。	適合大型資料集、線上學習與即時訓練。
小批次梯度下降 (Mini-batch SGD)	將資料切分成小批次，兼顧更新穩定性與效率，是深度學習中最常用方式。	適合中大型模型與可與 GPU 加速整合。

進階優化方法：學習率調整與收斂加速

方法名稱	主要機制與優勢	典型應用
動量法 (Momentum)	模仿物理動量，累積前幾次梯度方向，幫助克服震盪並加速收斂。	深層神經網路、對收斂速度要求高的任務。
Adagrad	根據參數歷史梯度大小自動調整學習率，適合稀疏特徵。	適用稀疏資料，限制於學習率會隨時間過度衰減。
RMSprop	引入滑動平均修正 Adagrad 學習率過快下降問題，穩定非穩定梯度訓練。	語音處理、序列建模等非凸問題。

方法名稱	主要機制與優勢	典型應用
Adam	結合動量與 RMSprop，追蹤梯度一階與二階矩，自動調整學習率。	深度學習中最常用優化器，適用於混合、語言、推薦、自動調整學習率等多數模型。

收斂判準與訓練穩定性

優化演算法的核心目標是持續調整參數，使損失函數逐步下降，但「何時訓練完成」與「訓練是否穩定」並非自動保證，因此須設定收斂判準及維持訓練穩定。

1. 常見的收斂判準 (Convergence Criteria)

判準	說明
損失函數變化趨緩	損失在連續多次迭代中變化幅度低於設定的 ϵ ，表示進入平緩階段，視為收斂。
驗證集效能不再提升	驗證集上的準確率或 F1 分數持續持平甚至下降，代表模型泛化能力達上限，繼續訓練會導致過擬合。
梯度趨近零	模型參數梯度值持續逼近零，表示損失函數位於平坦區域，參數更新幅度極小，為收斂跡象。
訓練步數或時間達上限	設定固定迭代輪數 (epoch) 或最大訓練時間作為結束條件，通常需配合其他指標使用，避免未收斂即停止。

2. 訓練穩定性的重要性

穩定訓練確保模型學習曲線平滑且預測逐步改善；震盪、發散或梯度爆炸會導致學習失敗。

不穩定因素	原因與影響
學習率過高	參數更新步次過大，導致最小值附近震盪或完全發散。
初始權重設置不當	容易陷入極端值或鞍點，學習無法啟動或停滯於局部極小值。
損失函數或資料分佈不連續	造成梯度訊號不穩定，影響收斂路徑。
批次大小 (Batch Size) 過小	梯度估計變異大，更新方向不穩定。

3. 常用穩定訓練策略

策略	說明
學習率調整 (Learning Rate Scheduling)	隨訓練進行自動降低學習率 (如 Step Decay、Cosine Annealing、ReduceLROnPlateau)，避免後期更新過大震盪。
提早停止 (Early Stopping)	驗證集效能連續多次 (epoch) 未改善即終止訓練，防止過擬合。
梯度裁剪 (Gradient Clipping)	限制梯度最大值，防止梯度爆炸及數值不穩定，特別適用於 RNN 與生成模型。
批次正規化 (Batch Normalization)	在每層中標準化中間輸出，使輸入分佈穩定，提升收斂速度與模型穩定性。

機器學習與統計基礎題目解析

問題編號	問題概要	正確選項	詳細解析
1	連續隨機變數機率分佈函數	(C)	機率密度函數 (PDF) 用於描述連續型隨機變數的取值範圍內的機率，透過積分計算區間機率，PMF 用於離散型變數。
2	伯努利分佈隨機變數可能取值	(B)	伯努利分佈為典型二元分佈，取值為 0 或 1，如成功與失敗、分類模型基礎。
3	主成分分析中的矩陣分解技術	(C)	PCA 透過特徵值分解協方差矩陣，找出最大變異方向以降維並保留重要資訊。
4	高維資料映射至低維空間且保留主要變異的方法	(C)	主成分分析 (PCA) 透過線性變換找出主要變異方向，達到降維與特徵提取效果。
5	梯度下降中梯度代表的含義	(C)	梯度為損失函數對參數的偏微分，指示參數調整方向與幅度以減少誤差。
6	顯著水準 (α) 在假設檢定中的定義	(C)	顯著水準為假設檢定時容許的一錯誤率，常設為 0.05，意即容許 5% 誤拒機率。
7	資料集中趨勢中不受極端值嚴重影響，適用於偏態分佈或有異常值資料。	(D)	Adagrad 根據歷史梯度平方和調整學習率，適合稀疏特徵資料。
8	會累積歷史梯度調整學習率的優化方法	(B)	梯度裁剪限制梯度最大值，防止梯度爆炸及數值溢出，特別適合深度神經網路及 RNN。
9	深度學習中梯度爆炸時優先採用的技術	(B)	

問題編號	問題概要	正確選項	詳細解析
10	邏輯迴歸處理二元分類時假設目標變數的分佈	(C)	邏輯迴歸假設目標變數服從伯努利分佈，並利用sigmoid函數將預測映射至[0,1]機率。

機器學習與深度學習基礎

1. 機器學習 (Machine Learning, ML) 概述

透過資料自動學習規律，從而預測、分類或決策，不依賴人工規則，而是從資料中萃取模式，廣泛應用於語言、影像、醫療、金融等。

2. 機器學習的基本結構

元素	說明
輸入資料與特徵空間	來源多元（結構化表格、文字、影像、語音等），必須轉換為向量或矩陣表示。特徵空間為多維空間，影響分類與預測效果。
任務目標與標籤型態	包含分類（離散標籤）、迴歸（連續標籤）、聚類（無標籤分群）、降維（低維表示）、序列決策（最大化長期報酬）。
模型與假設空間	模型為輸入映射至預測結果的函數，假設空間反映模型對資料結構的假設，如線性模型、決策樹、神經網路等。
學習目標與損失函數	損失函數量化預測與真實誤差，決定學習方向與收斂路徑。常見損失函數：均方誤差(MSE)、平均絕對誤差(MAE)、交叉熵損失(Cross-Entropy)。
資料分割與評估準則	資料分為訓練集、驗證集、測試集。評估指標包括準確率、召回率、F1分數、迴歸用R ² 、MSE、決定係數(R ²)。

3. 監督式學習 (Supervised Learning)

內容	說明
基本架構	利用標註資料學習映射函數，根據輸入特徵預測目標標籤。
主要任務類型	分類（離散標籤，如垃圾郵件分群、影像辨識）與迴歸（連續標籤，如房價預測）。
訓練流程與評估方法	資料準備 → 模型訓練 → 驗證調整 → 測試部署。透過損失函數最小化誤差，並用驗證集避免過擬合。
應用場景	圖像分類、信用風險評估、醫療診斷等，效能依賴標註品質與特徵設計。

4. 非監督式學習 (Unsupervised Learning)

內容	說明
基本架構	無標註資料，尋找資料潛在結構與分佈特性，如分群、降維、關聯規則、潛在表示學習。
主要任務類型	聚類(Clustering)、降維(Dimensionality Reduction)、關聯規則學習、潛在表示學習。
訓練流程與評估方法	資料標準化 → 模型選擇與超參數設定 → 模型擬合迭代。評估使用內部指標（如Silhouette score）、外部指標（如Rand Index）與視覺化輔助分析。
應用場景	客戶分群、異常偵測、影像壓縮、主題模型、特徵工程等，常用於探索資料結構與非監督學習的處理。

5. 強化式學習 (Reinforcement Learning, RL)

元素	說明
基本架構	代理人(Agent)與環境(Environment)互動，觀察狀態(State)、執行動作(Action)，獲得報酬(Reward)，根據策略(Policy)學習決策。
重要組成	狀態(State)、動作(Action)、報酬(Reward)、策略(Policy)、價值函數(Value Function)。
任務類型	策略學習(Policy Learning)、價值學習(Value-Based)、模型式(Model-Based)、模型無關(Model-Free)學習。
訓練流程	初始化策略/價值函數 → 與環境互動收集經驗 → 根據報酬更新策略或價值 → 反覆試誤提升決策能力。
評估方法	透過模擬或實際環境測試長期績效，指標如平均累積報酬(Average Reward per Episode)、成功率等。

強化式學習應用與挑戰

強化式學習 (Reinforcement Learning) 強調動態環境中的策略調整與決策，具有適應性強的特點，廣泛應用於多種高複雜度場景。

應用場景	範例與描述
遊戲AI與對弈系統	AlphaGo、OpenAI Five、DeepMind Atari 等，強化學習用於策略優化與決策。
自駕車與機器人控制	動作序列學習、導航決策與連續控制，提升自主運動與反應能力。
推薦系統與廣告分發	利用即時反饋機制優化推薦效果，最大化長期使用者價值。
金融投資與資源配置	連續決策過程中結合風險控制與策略調整，強化投資策略的應用。
運輸與物流排程	多階段決策與最短路徑規劃，提升運輸效率與排程品質。

挑戰：

- 樣本效率低
- 訓練不穩定
- 實務部署門檻高

監督式學習：迴歸任務

迴歸分析核心概念

迴歸分析 (Regression) 用於預測連續型目標變數，透過建立輸入特徵與目標之間的數學模型，達成精準預測與關係描述。

主要迴歸模型比較表

模型類型	主要特點	適用情境	限制與挑戰
線性迴歸	假設自變數與應變數呈線性關係，模型可解釋性高	變數間線性、資料規模適中	對離群值敏感，無法捕捉非線性關係
Lasso迴歸	損失函數含L1正則化，可壓縮部分係數為零，具備特徵選擇功能	多重共線性、變數多於樣本數	變數高度相關時可能忽略部分變數
嶺迴歸 (Ridge)	損失函數含L2正則化，防止係數過大，適合多重共線性情況	多重共線性、預防過擬合	無法將係數壓縮為零，無法特徵選擇
支援向量迴歸	可透過核函數支持非線性映射，該函數可將輸入資料點映射到高維空間，抗離群值	非線性資料、資料規模中小	計算複雜度高，參數調整困難
決策樹迴歸	非參數模型，透過資料分割捕捉非線性關係，預測結果為葉節點平均值	非線性關係、類別與數值混合資料	易過擬合，模型不連續，對數據敏感
集成式迴歸	結合多模型優點，提升預測精度與穩定性	大量複雜資料	模型解釋力有限，訓練與預測成本較高

線性迴歸 (Linear Regression)

模型公式

$$y = \beta_0 + \beta_1x_1 + \beta_2x_2 + \dots + \beta_nx_n + \epsilon$$

- y ：目標變數（應變數）
- β_0 ：截距 (Intercept)
- β_j ：第 j 個自變數的迴歸係數 (Slope)
- x_j ：第 j 個自變數（輸入特徵）
- ϵ ：誤差項，表示模型無法解釋的隨機變異

模型評估指標

指標	定義與特性
平均平方誤差 (MSE)	預測值與實際值誤差平方的平均，越小越準確
均方根誤差 (RMSE)	MSE的平方根，單位與目標變數相同，易於解讀
平均絕對誤差 (MAE)	預測誤差絕對值的平均，對離群值較不敏感
決定係數 R^2	模型解釋目標變數變異比例，範圍0~1，越接近1解釋力越強
調整後 R^2	考慮模型複雜度調整的 R^2 ，適合比較不同模型

模型假設

假設項目	說明
線性關係	自變數與應變數間存在線性關係
誤差常態分佈	誤差項 ϵ 須符合常態分佈
變異數齊一性	誤差項變異數在不同自變數值下應相同
誤差獨立性	各觀測值間誤差獨立無關
無多重共線性	自變數間不應高度相關，避免影響係數估計穩定性

使用限制

- 對離群值敏感，極端值可能影響係數
- 無法捕捉非線性關係
- 多重共線性會造成係數不穩定
- 假設若違反，預測與推論可能失真

Lasso迴歸與嶺迴歸 (Ridge Regression)

定義與正則化

模型	損失函數形式	功能與特點
Lasso迴歸	$Loss = \sum (y_i - \hat{y}_i)^2 + \lambda \sum \beta_j $	L1正則化，限制係數大小，能將部分係數縮為零，達到特徵選擇效果
嶺迴歸	$Loss = \sum (y_i - \hat{y}_i)^2 + \lambda \sum \beta_j^2$	L2正則化，防止係數過大，適合多重共線性嚴重情況

- λ ：正則化係數，控制限制強度
- y_i ：目標變數
- $\hat{y}_i$ ：預測值
- β_j ：迴歸係數

模型評估指標

同線性迴歸使用MSE、RMSE、MAE、 R^2 、調整後 R^2 。

模型假設

與線性迴歸相同，包括線性關係、誤差常態分佈、變異數齊一性、誤差獨立性及無多重共線性。

適用情境

- 存在多重共線性
- 變數數量遠大於樣本數（高維資料）
- 預防過擬合
- 需要特徵選擇（Lasso）
- 預測精度重於解釋度

使用限制

Lasso限制	嶺迴歸限制
高度相關變數可能只保留一個	無法將係數壓縮至零，無一特徵選擇
λ 選擇不當可能導致欠擬合	無法直接簡化模型結構

Lasso限制	嶺迴歸限制
對非線性關係無法建模	正則化係數需透過交叉驗證選擇

支援向量迴歸 (Support Vector Regression, SVR)

定義

SVR是支援向量機 (SVM) 的迴歸版本，透過尋找最能描述資料趨勢的超平面，使預測誤差在容差範圍 ϵ 內，並最小化超出範圍的誤差。

模型公式與目標

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*)$$

- w ：權重向量，定義超平面方向
- ξ_i, ξ_i^* ：超過容差範圍的誤差變量
- C ：正則化參數，控制模型複雜度與誤差容忍度
- ϵ ：誤差容忍範圍 (ϵ -tube)

迴歸函數：

$$f(x) = w \cdot x + b$$

非線性形式（配合核函數 $K(\cdot, \cdot)$ ）：

$$f(x) = \sum_{i=1}^n \alpha_i K(x_i, x) + b$$

模型評估指標

同線性迴歸常用指標：MSE、RMSE、MAE、 R^2 、調整後 R^2 。

模型假設與優勢

特點	說明
非嚴格線性假設	可利用核函數映射非線性資料
不要求誤差常態分佈	偏離傳統線性迴歸假設
抗離群值能力強	忽略誤差小於 ϵ 的資料點
假設資料可分或近似可分	需滿足可分離條件

適用情境

- 非線性關係資料
- 中小規模資料集，維度不過高
- 需抗離群值能力

使用限制

限制項目	說明
計算複雜度高	大型資料集或高維度下計算資源需求大
參數設定複雜	依賴 C 、 ϵ 、核函數及其參數調整
解釋性差	非線性核函數使模型難以直觀理解
不適合極大規模資料	訓練時間與記憶體需求隨樣本數平方增長

決策樹迴歸 (Decision Tree Regressor)

定義與核心概念

決策樹迴歸透過根據特徵分割資料，形成分支與葉節點，葉節點預測值為該區塊樣本目標值平均，能捕捉非線性與複雜資料結構。

預測流程

- 從根節點根據特徵及閾值分割資料為左右子節點
- 重複分割，直到達到最大深度、節點樣本數下限或變異度足夠小。
- 葉節點以該節點所有樣本目標值平均作為預測值。

模型評估指標

同上：MSE、RMSE、MAE、 R^2 、調整後 R^2 。

模型假設

非參數模型，不需線性關係、誤差常態、變異數齊一、多重共線性。

適用情境

- 預測連續目標變數
- 非線性或高階交互作用資料
- 需具邏輯分支易解釋模型
- 類別型與數值型混合特徵
- 中小至中大型資料集

使用限制

限制項目	說明
容易過擬合	單棵樹可能完全擬合訓練集，泛化能力弱
預測結果不連續	預測為分段常數，目標值連續變化時可能出現跳躍
對資料微小變動敏感	稍微變動資料可能導致樹結構大幅變化，影響穩定性
捕捉複雜邊界能力有限	高維空間中單棵樹表現受限

集成式迴歸 (Ensemble Regression)

定義與核心概念

集成式迴歸透過結合多個模型預測，利用「群體智慧」提升整體精確度與穩定性，降低錯誤與過擬合風險。

主要方法比較

方法	特點	優勢	缺點
隨機森林迴歸	多棵決策樹基於隨機子樣本與隨機特徵分割，預測值為樹結果平均	抗過擬合強，能處理非線性與高階交互作用	模型解釋性低，體積大，預測速度較慢
梯度提升迴歸	序列表訓練，逐步修正前一個模型的殘差，提升預測精度	高預測精度，靈活損失函數，早停減少過擬合	訓練慢，易過擬合，超參數調整複雜，解釋性差

高效梯度提升方法

工具	特點與優勢
XGBoost	運算效率高，利用二階導數加速分裂點搜尋，支援稀疏資料與缺失值，層數式生長 (Level-wise) 策略。
LightGBM	採用葉子式生長 (Leaf-wise) 策略，計算更快，適合大數據與高維特徵，記憶體使用效率佳，支援並行運算。

特點與缺點

特點	缺點
高運算效率	參數多且複雜，學習曲線陡峭
支援缺失值與稀疏資料	解釋力有限，模型仍屬黑箱

特點	缺點
支援並行運算	記憶體需求高，葉子式策略易過擬合（需參數限制）
先進分析策略與特徵重要性	預測結果不平滑，對某些非线性（價格曲線等）可能不理想

監督式學習：分類任務

分類定義與應用

分類 (Classification) 用於預測離散類別結果，包含二元與多類別問題，廣泛應用於郵件垃圾分類、客戶流失預測、疾病診斷等。

分類模型選擇考量

模型類型	優點	缺點	適用情境
邏輯迴歸	簡單易解釋，適合二元分類	無法捕捉複雜非線性邊界	小至中等規模，需求解釋性高
支援向量機 (SVM)	處理高維資料能力強	計算成本高昂，參數調整複雜	中小規模，需高精度分類
集成方法 (隨機森林、梯度提升)	高準確度，能處理複雜資料	模型難以解釋	大資料集，精度優先

邏輯迴歸 (Logistic Regression)

定義

雖名為迴歸，實際用於二元分類，根據輸入特徵預測屬於正類 (Class 1) 的機率。

模型公式

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1x_1 + \beta_2x_2 + \dots + \beta_nx_n)}}$$

- p ：屬於正類的機率
- β_0 ：截距
- β_j ：特徵係數
- x_j ：特徵值

評估指標

指標	說明
Accuracy	預測正確比例（正確預測正類與負類占總樣本比例）
Precision	預測為正類中真正正類比例
Recall	真正正類中被正確預測為正類比例
F1-score	Precision與Recall的調和平均，用於綜合評估模型效果

不平衡資料下的表現與評估指標

ROC-AUC（接收者操作特徵曲線下面積，Receiver Operating Characteristic - Area Under Curve）

衡量模型區分正、負類的能力，值越接近1表示模型表現越好。

邏輯迴歸模型 (Logistic Regression)

項目	說明
模型假設	- 線性可分性 (Linearity in Log-Odds)：特徵與對數勝率之間呈線性關係。資料獨立性：觀測值彼此獨立。無多重共線性：避免特徵高度相關導致係數不穩定。
關鍵概念	對數勝率 (Log-Odds) ：事件發生機率與不發生機率比值的自然對數，將機率[0,1]轉換為 $(-\infty, +\infty)$ ，方便線性建模。
適用情境	- 二元分類問題（例如是否購買、是否患病）。需解釋模型原因的領域（金融、醫療）。特徵數不多且資料量適中。
限制	- 無法捕捉複雜非線性邊界。對離群值敏感，影響係數估計。需滿足假設條件，否則效果差。

多類別分類擴展

- 使用方法：One-vs-Rest (OvR)、多項式邏輯迴歸 (Multinomial Logistic Regression)

支援向量機 (Support Vector Machine, SVM)

項目	說明
定義	透過尋找最大化邊界 (Margin) 的超平面區分不同類別。可用核函數映射資料到高維空間處理非線性問題。
模型公式	決策邊界： $w \cdot x + b = 0$ 判斷正負類： $w \cdot x + b > 0$ 為正類，反之為負類 核函數決策函數： $f(x) = \sum \alpha_i y_i K(x_i, x) + b$
參數說明	w ：權重向量 x ：輸入特徵向量 b ：偏置量（截距） α_i ：支援向量權重 y_i ：支援向量標識 $K(\cdot)$ ：核函數
常見核函數	線性核、多項式核、徑向基函數 (RBF/Gaussian)、Sigmoid核
模型假設	適用線性或近似線性可分資料；核函數允許非線性邊界；高維空間表現佳；適合小型至中型資料集。
適用情境	中小規模資料，需精確度最高，邊界清晰，特徵罕見。
限制	計算成本高昂，尤其大資料集；參數調整複雜，特別是懲罰參數 C 與核參數 γ

決策樹分類器 (Decision Tree Classifier)

項目	說明
定義	透過「如果...那麼...」規則依特徵分割資料，最終在葉節點給出類別預測，流程圖式的分類模型。
建樹流程	a. 選擇特徵與最佳切分點 b. 分割資料 c. 重複直到達到最大深度、樣本數低於閾值或純度足夠

項目	說明
	• 基尼不純度 (Gini Impurity)：衡量節點混雜程度，越小時訊增益 (Information Gain)：熵變化量。分類誤差 (Classification Error)
評估指標	
模型假設	無線性關係；能處理混合型特徵；捕捉變數交互作用；對資料尺度不敏感 (無需標準化)
適用情境	類別型預測，需易解釋模型，資料集規模中小
限制	易過擬合；對資料微小變動敏感。決策邊界不連續，呈階梯狀；效能低於集成方法

項目	說明
定義	非參數、惰性學習分類演算法，不建立模型，依新點與訓練集中K個最近鄰點分類別決定分類。
核心原理	a. 計算距離 (歐幾里得、曼哈頓等) b. 選取K個最近鄰 c. 多數投票決定類別
模型假設	「近朱者赤」：相近點特性相似，類別相同 特徵尺度影響距離，需特徵縮放 維度詛咒：高維空間距離均勻，效能降低
適用情境	資料量適中、特徵維度不高、複雜但局部清晰的決策邊界 無需訓練階段 (惰性學習) 多類別分類可直接應用
限制	預測時計算成本高 對離群值敏感，需選擇合適K值 過小受噪聲影響，過大模糊邊界 高維度資料效能差，需特徵縮放

項目	說明
定義	基於貝氏定理並假設特徵條件獨立的機率分類演算法，計算後驗機率分配類別。
貝氏定理公式	

$$P(C|X) = \frac{P(X|C) \times P(C)}{P(X)}$$

其中 $P(C X)$ 為後驗機率， $P(X C)$ 為似然度， $P(C)$ 為先驗機率， $P(X)$ 為證據。	
模型假設	特徵條件獨立性： $P(X C) = \prod P(x_i C)$ ，簡化計算。
適用情境	文本分類 (垃圾郵件、情感分析)、大規模數據、多類別問題、需快速預測。
限制	強獨立性假設可能不成立 影響性能

零機率問題須平滑技術 (如拉普拉斯平滑) 解決對數據分布敏感
不適用於迴歸問題 |

項目	說明
定義	結合多個模型預測提升準確度與穩定性，核心為「群體智慧勝單一模型」。
分類策略	• 每基模型預測類別標籤或機率，最終透過投票或機率平均決定結果
核心方法	Bagging (降低變異性，代表演算法：Random Forest) Boosting (降低偏差，代表演算法：Gradient Boosting, XGBoost、LightGBM)
決策機制	投票 (多數決或加權投票) 機率輸出 (如 Softmax) 多類別策略 (One-vs-Rest、One-vs-One)
常用評估指標	Accuracy、Precision、Recall、F1-score、ROC-AUC

項目	說明
介紹	多棵決策樹組成的集成方法，隨機抽樣資料與特徵訓練，每棵樹投票決定分類結果。
特點	抗過擬合強；能處理非線性及變數交互；對不平衡資料較有抵抗力；可計算特徵重要性；訓練可平行化。
缺點	模型解釋度低 (黑箱)；記憶體需求大；對極端不平衡資料仍偏多數類；難以提供平滑機率估計。

項目	說明
介紹	Boosting類型，逐步建立決策樹修正前一棵樹的錯誤，每棵加權整合所有弱學習器結果。
特點	準確度高於隨機森林；能捕捉複雜非線性；支援多類別；損失函數自訂；支援Early Stopping防過擬合。
缺點	訓練時間長；易過擬合需謹慎調參；解釋度差；超參數多。

⚡ XGBoost 與 LightGBM

項目	說明
介紹	Gradient Boosting 高效實現，解決大數據與計算瓶頸。支持多類別與機率輸出。
XGBoost特色	使用二階導數 (Hessian) 加速分裂；自動處理缺值；層級式生長策略。
LightGBM特色	採Leaf-wise分裂策略快速降低Loss；Histogram計算；大數據上速度更快。
共同特點	計算快；適用大數據高維度；支援並行計算；可分析特徵重要性；Kaggle常勝軍。
缺點	超參數多；解釋度差；記憶體需求高；Leaf-wise策略易過擬合 (LightGBM特有)。

非監督式學習 (Unsupervised Learning)
- 無標註資料，自主探索數據內在結構與規律。 - 應用：顧客分群、數據視覺化/降維、異常偵測、關聯規則分析。

分群分析 (Clustering)

k-means 分群

步驟	說明
初始化	隨機選取K個資料點作為初始質心 (Centroid)
分配	將資料點分配至最近質心所屬群集
更新	計算群集內資料平均值作為新質心
重複	反覆分配與更新，直至質心不動或達最大迭代次數

- 優點：簡單快速，處理大量資料效率高。
- 缺點：需預先指定K；對初始質心和離群值敏感；只能形成凸形群集。

類型	說明
凝聚式 (Agglomerative)	自底向上，由單點開始逐步合併相似群集，形成樹狀結構 (Dendrogram)。
分裂式 (Divisive)	自頂向下，從整體群集逐步分割成子群集。

- 優點：無需指定K；提供樹狀視覺化；發現多層次群集。
- 缺點：計算複雜度高；對離群值敏感；合併/分裂不可逆，易陷入次優解。

DBSCAN (Density-Based Spatial Clustering of Applications with Noise)
- 基於密度的分群演算法，能辨識任意形狀群集並剔除噪聲 (離群值)。 - 主要參數： <i>Eps</i> (epsilon)：鄰域半徑。 <i>MinPts</i> (Minimum Points)：核心點所需最小點數-原理：從未訪問點開始，根據密度判斷核心點，形成群集並分離噪聲。

DBSCAN (Density-Based Spatial Clustering of Applications with Noise)
一種基於密度的群集方法，不需要事先指定群集數量，能發現任意形狀的群集，並有效識別噪聲點。

項目	說明
核心點	鄰域 (以半徑Eps定義) 內的點數≥MinPts的點。以此核心點開始，遞歸地將所有密度可達的點加入群集。
邊界點	鄰域內點數
噪聲點	鄰域內點數

- 運作流程**
- 找出核心點。
 - 以核心點為起點生成群集，遞歸添加密度可達點。
 - 重複直到所有點被訪問並分類。

優點	缺點
無需預先指定群集數量	對參數Eps和MinPts高度敏感，錯誤設定嚴重影響結果
能發現任意形狀群集，不受凸性限制	對密度不均勻群集效果不佳
能有效辨識及標記噪聲點	高維數據中定義合適密度和距離度量困難，表現可能不佳

▼ 降維技術 (Dimensionality Reduction)

將高維數據轉換為低維表示，保留重要資訊和結構，有助於數據視覺化、減少存儲與計算成本、緩解維度詛咒。

PCA (主成分分析)	線性降維，透過特徵值分解協方差矩陣，投影數據到最大變異方向的正交主成分上	數學基礎堅實，易理解，計算快，特徵正交。	僅捕捉線性變異，對離群值敏感。
t-SNE	非線性降維，將高維相似性以高斯分布表示，低維以t-分布表示，透過最小化KL散度優化映射。	保留局部結構，適合視覺化複雜非線性群集。	計算成本高，受隨機參數影響，多適合小數據下游任務。
UMAP	非線性降維，構建高維拓撲結構，最小化交叉熵以保留局部和全局結構。	運行快，能處理大數據，參數調整直觀，支持增量學習。	理論較複雜，理解門檻高，對參數敏感，受部分參數影響。

關聯規則學習 (Association Rule Learning)
從大型資料中發掘項目間有意義的關聯，常用於購物籃分析。 Apriori 演算法

特色	說明
核心理念	頻繁項集的子集必為頻繁；若項集不頻繁，其超集也不頻繁，減少搜索空間。
流程	由頻繁1項集開始，迭代生成候選集並剪枝，直到無新增頻繁項集，最後生成關聯規則。
衡量標準	支持度 (Support)、信賴度 (Confidence)、提升度 (Lift)

指標	數學定義	解釋
支持度	$P(A \cap B)$	規則 $A \Rightarrow B$ 在交易中同時出現頻率。
信賴度	$P(B A) = \frac{Support(A \cap B)}{Support(A)}$	在包含 A 的交易中同時包含 B 的比例。
提升度	$Lift(A \Rightarrow B) = \frac{Confidence(A \Rightarrow B)}{P(B)}$	> 1 表示正相關，< 1 負相關，= 1 獨立。

優點	缺點
概念簡單，易理解	大量數據與項目時計算成本高，需多次掃描資料集，效率低下

特色	說明
核心理念	利用FP樹 (頻繁模式樹) 結構，避免生成大量候選集，大幅降低計算量。
流程	先掃描資料計算支持度，過濾低支持度項目並排序；第二次掃描建立FP樹，遞歸挖掘頻繁項集。
優點	比Apriori更高效，兩次掃描完成，節省記憶體與計算。
缺點	大型複雜資料集建構需大量記憶體，極度稀疏資料壓縮效果差。

異常偵測 (Anomaly Detection)
識別資料中與大多數資料行為顯著不同的點，常用於錯誤檢測、欺詐識別、設備故障等。 Isolation Forest (孤立森林)

特點	說明
核心思想	異常點較少且與正常點距離遠，容易被少次分割孤立。
運作流程	隨機選擇特徵與分割點建立孤立樹，遞歸劃分直到點被孤立，根據平均路徑長度計算異常分數。
優點	效率高，適合高維及大數據，不需距離計算，直接輸出異常分數，適合不平衡數據。
缺點	靠近正常群集的異常難檢測，異常不孤立時效果差，結果受隨機性影響。

特點	說明
定義	單類別分類器，學習正常數據模式，建立決策邊界，將邊界外點視為異常。
運作流程	利用核函數將數據映射至高維空間，尋找將正常點與異常點分離的超平面作為邊界。
優點	處理非線性邊界，高維數據表現良好，僅需正常數據訓練。
缺點	對參數敏感，計算成本高，混入異常點會影響邊界精確度。

深度學習原理與架構

人工神經元 (Artificial Neuron)

受生物神經元啟發的數學模型，輸入多個訊號加權求和後，經激活函數輸出。

元件	說明
輸入訊號	$x_1, x_2, \dots, x_n$ ，來自其他神經元或外部數據。
權重	$w_1, w_2, \dots, w_n$ ，表示輸入訊號重要性。
加權求和	

$$Z = \sum_{i=1}^n w_i x_i + b$$

其中b是偏置項，調整激活閾值。
激活函數

感知器 (Perceptron)

最簡單的人工神經元模型，1957年由Frank Rosenblatt提出，為二分類器。

特點	說明
激活函數	步階函數： $f(x) = \begin{cases} 1 & x \geq 0 \\ 0 & x < 0 \end{cases}$

運作流程	輸入加權求和後通過步階函數，輸出二分類結果。
學習規則	根據預測錯誤迭代調整權重和偏置以減少錯誤。
優勢	簡單易懂，可解決線性可分問題。

限制	無法解決非線性可分問題，如XOR問題。

角色	說明
引入非線性	無激活函數，神經網路只能擬合線性關係，無法處理複雜非線性問題。
決定神經元激活狀態	根據加權和決定神經元是否激活並傳遞訊號，模擬生物神經元行為。
壓縮輸出範圍	如Sigmoid壓縮至[0,1]，有助於穩定訓練與解釋輸出為機率。

前向傳播 (Forward Propagation)
神經網路進行預測的過程，將輸入資料層層傳遞並計算輸出。

步驟	說明
數據輸入	原始數據輸入到輸入層。
層層計算	每層神經元計算加權和後通過激活函數，輸出作為下一層輸入。
訊息傳遞	層層向前推進直到輸出層。
輸出結果	產生預測值，如分類標籤或迴歸數值。

反向傳播 (Backpropagation)
神經網路學習關鍵，計算損失函數對權重的梯度，調整參數以提升預測準確度。

步驟	說明
計算損失	比較預測與真實標籤，透過損失函數量化誤差。
計算梯度	利用微分連鎖律，將誤差從輸出層反向傳遞至每層，計算權重梯度。
更新權重	根據梯度調整權重與偏置，減少下次預測誤差。

步驟	說明
從輸出層開始	對損失函數計算導數，取得輸出層的梯度。
逐層反向傳遞	利用連鎖律 (Chain Rule)，將梯度從後層傳至前層，計算每層參數的梯度。
接收前層梯度	每層根據來自後層的梯度和激活函數的導數，計算本層權重及偏置梯度。
傳遞前層梯度	將本層梯度傳遞給更前面的層，以此類推直到輸入層。

權重更新
- 使用優化器 (如梯度下降法) 根據計算出的梯度和學習率調整權重與偏置。 - 更新方向沿梯度相反方向，確保損失函數下降最快。 - 例：如果某權重使損失增加，梯度告訴我們應該減少該權重。 迭代學習循環 - 前向傳播計算預測值 → 計算損失 → 反向傳播計算梯度 → 優化器更新參數。 - 重複此過程數千至數百萬次，逐步降低損失，提高模型精確度。

損失函數與優化器
損失函數 (Loss Function)
衡量模型預測結果與真實值誤差大小的函數，輸出為單一數值，數值越低表示模型表現越好。

作用	說明
評估誤差	提供模型預測準確度的量化標準。
指引優化	損失函數值為優化器調整模型參數的依據。

任務類型	損失函數名稱	說明
迴歸	均方誤差 (Mean Squared Error, MSE)	預測值與真實值差平方的平均。
	平均絕對誤差 (Mean Absolute Error, MAE)	預測值與真實值差絕對值的平均，對離群值敏感度低。
分類	交叉熵損失 (Cross-Entropy Loss)	衡量預測機率分佈與真實類別分佈的距離。
	二元交叉熵	用於二元分類問題 (是/否判斷)。
	類別交叉熵	用於多分類問題。

優化器 (Optimizer)
- 根據損失函數輸出與梯度調整模型參數，目標是使損失函數最小化。 - 常用方法包含梯度下降法及其變種。



過擬合與正則化技術

過擬合 (Overfitting)

模型在訓練資料表現優異，但在未知資料 (測試集) 上表現差，原因多為模型過於複雜或訓練數據不足。

產生原因	說明
模型過於複雜	參數過多，層數太深，導致模型「記憶」訓練資料中的噪聲。

框架	開發者 / 支持機構	主要特性與用途	生態系統與工具
JAX	Google	結合NumPy易用性、自動微分、GPU/TPU加速，偏向數值計算庫	主要用於機器學習轉換，不是端端框架
MXNet	Amazon Web Services (AWS)	多語言支援，是合式程式設計（符號式 + 命令式）	適合多語言環境與混合編程風格
PaddlePaddle	百度等	具特定優勢與定位，詳細內容未提及	針對中文環境和特定應用有所優化

機器學習基礎問答解析

問題編號	題目重點	正確答案	解析重點
1	無標註資料在群組或模式	非監督式學習 (Unsupervised Learning)	不依賴標註資料，包含分類與降維資料分析工具
2	監督式學習中預測連續數值的任務	迴歸 (Regression)	用於連續數值預測，如房價、溫度
3	學習資料局部特徵的深度學習架構	卷積神經網路 (CNN)	利用卷積層偵測局部特徵，適合影像、聲音等有空間或時間結構資料
4	支援向量機用於迴歸時的稱呼	支援向量迴歸 (Support Vector Regression, SVR)	尋找最佳超平面，使大部分資料點落在預設誤差範圍內
5	模型過度學習導致訓練資料噪聲現象	過擬合 (Overfitting)	模型在訓練資料表現良好但泛化能力差，因模型複雜學習到噪聲
6	深度學習中引入非線性元件	激活函數 (Activation Function)	如ReLU、Sigmoid，讓多層網路非線性化，學習複雜模式
7	降低過擬合風險的方法	正則化 (Regularization)	在損失函數加入懲罰項 (L1、L2)，限制權重大小，提升泛化能力
8	計算模型預測與實際差距的函數	損失函數 (Loss Function)	衡量預測誤差，常見如均方誤差 (MSE)、交叉熵損失
9	Transformer模型核心機制	注意力機制 (Attention)	計算序列元素間關聯權重，捕捉長距離依賴，替代傳統RNN架構
10	決策樹分裂效果判斷指標	基尼不純度 (Gini Impurity)	衡量節點樣本不純度，數值越低表示越集中於單一類別，常用於分類任務

機器學習建模與參數調校流程

1. 數據準備與清理

項目	處理方法與說明
缺失值處理	刪除法 (刪除少量缺失且無偏樣本)、填補法 (均值、中位數、眾數、KNN、預測模型填補)、缺失指標編碼 (新增缺失類別)
異常值偵測與處理	統計方法 (Z-score、IQR)、視覺化分析 (箱型圖、散佈圖)、機器學習方法 (Isolation Forest、LOF)；處理：移除、截尾轉換、標記保留
重複樣本檢查	透過主鍵或欄位相似度判斷，避免重複樣本影響訓練
資料一致性	統一單位 (如公斤、公尺)、時間格式、類別值標準化
資料型態別轉換	數值與類別型資料正確標示，時間資料轉換為時間戳、週期性特徵
資料清理策略	根據模型特性調整，樹模型容錯較高，線性模型與神經網路嚴格處理；保持資料處理流程可追溯性與合規性

2. 特徵選擇與降維

方法分類	方法名稱	特點與說明	優點	限制
Filter	皮爾森相關係數、卡方檢定、ANOVA	獨立於模型，快速篩選重要特徵	速度快，不依賴模型	無法考慮特徵間互動
Wrapper	遞迴特徵消除 (RFE)、前向/後向選擇	以模型表現為依據篩選特徵	考慮特徵互動	計算成本可能高，可能過擬合
Embedded	決策樹重要性分析、Lasso、Ridge	在模型訓練過程中內建特徵選擇機制	同時完成特徵選擇	依賴特定模型或超參數

方法分類	方法名稱	特點與說明	優點	限制
降維	PCA、LDA、t-SNE、UMAP、SVD	降低維度，保留主要資訊；PCA最大化資料變異，LDA最大化類間差異，t-SNE/UMAP保留鄰近關係，SVD用於矩陣分解	提高模型效率與視覺化	非線性降維不適合直接建模

3. 特徵轉換與資料標準化

轉換類型	方法	特點與適用情況
尺度調整 (Scaling)	Min-Max Normalization	線性縮放至0~1，保留比例，對極端值敏感
	Z-score Standardization	轉換成平均0、標準差1的常態分布，適合常態資料，對極端值仍敏感
	Robust Scaling	用中位數與IQR縮放，對極端值抵抗強力，適用有偏態或含離群值資料
分佈轉換	對數轉換 (Log Transform)	處理右偏分布，降低極端值影響
	平方根 / 立方根轉換	溫和壓縮變異性，適用中度偏態資料
	Box-Cox / Yeo-Johnson	自動尋找最適指數，將資料近似常態化
類別資料處理	Label Encoding	類別轉為整數，適用有序類別，易誤用於無序類別導致致性誤解
	One-hot Encoding	無序類別轉為二元欄位，保留完整類別資訊，類別基数高時維度爆炸
	Target Encoding	以目標變數統計量替代類別，適用高基数且與目標高度相關類別
時間與週期性資料轉換	時間欄位拆解為年、月、日、星期等結構化特徵，週期性特徵用三角函數編碼	保留週期性結構，提升模型對時間相關性識別能力

以上內容涵蓋了本次講義所討論的深度學習框架生態、機器學習基本概念問答解析，以及機器學習建模前中後的完整數據處理、特徵工程和標準化流程。學生可依此詳細掌握考試重點與實務應用。

資料增強 (Data Augmentation)

資料增強是透過產生新樣本或變現現有樣本，增加資料量並改善資料平衡，提升模型的泛化能力與穩定性。

資料類型	常見方法	應用案例
圖像資料增強	隨機翻轉、旋轉、裁切、縮放、色彩變換	影像辨識 (如人脸识别)、醫學影像分析
文字資料增強	同義字替換、隨機刪除、隨機交換字詞位置	情感分析、主題分類、對話模型
時序資料增強	增加噪聲、局部時段調整 (Scaling、Jittering)、窗口裁切	設備故障預測、股市趨勢分析
表格式資料增強	SMOTE (合成少數過採樣技術)、Synthetic Minority Oversampling Technique)	不平衡資料分類 (如詐欺偵測、疾病診斷)

特徵工程策略

特徵工程結合資料理解、領域知識與建模目標，是有目的、有規劃的決策過程。

思考方向	詳細說明
依任務類型設計特徵	分類任務偏好離散分群特徵 (類別指標、區間編碼)；迴歸任務偏好連續特徵。
依模型性質調整特徵	線性模型需注意尺度與共線性；樹模型避免過度編碼誤用；距離式模型需確保特徵單位一致。
探索資料隱含結構	合成新欄位 (如「單價 × 數量」生成總價)；統計色彩 (如「使用者過去7天點擊次數」)
考慮時間性與序列關聯	提取滯後值 (lag)、移動平均 (rolling mean) 等序列特徵；加入時間間隔、事件次數等動態指標

模型選擇與架構設計

1. 任務類型與模型特性配對

任務類型	目標	常見模型與說明	應用案例
分類任務	預測資料所屬的離散類別	決策樹：隨機森林：具解釋性，適合混合且分佈複雜資料。支援向量機 (SVM)：適合高維小樣本。神經網路：適合高維非線性或語言資料。	垃圾郵件偵測、疾病診斷、客戶流失預測

任務類型	目標	常見模型與說明	應用案例
迴歸任務	預測連續數值輸出	線性迴歸：結構簡單，決策容易。隨機森林迴歸：非線性處理能力強。神經網路：適合高維、大規模非線性資料。	房價預測、能源消耗預測、業績估算
非監督學習任務	發掘潛在結構或隱含關係	聚類：K-means：適合球狀資料與已知群數。DBSCAN：適合含噪聲、不均群大小降維。PCA (主成分分析)：保留最大變異方向。自編碼器 (Autoencoder)：非線性降維。	聚類分析、資料壓縮
序列與時間序列任務	根據序列資料做預測或決策	RNN / LSTM / GRU：長序列依賴。時序卷積網路 (TCN)：穩定長期依賴。ARIMA：短期週期性資料與小規模應用。	股價預測、感測器監控、語音辨識

2. 資料規模與模型選擇

資料規模	特點與選擇策略
小型資料集	數百至數千筆，偏好結構簡單、參數少的模型，如線性迴歸、邏輯迴歸、決策樹、正則化模型 (Lasso、Ridge)，需加強資料前處理與特徵工程。
中型資料集	數千至數十萬筆，支持較高表現力模型如隨機森林、梯度提升機 (XGBoost、LightGBM)，可嘗試模型集成與超參數優化。
大型資料集	百萬級以上，適合深度神經網路，特別是結構化資料 (影像、語言、文字)，需考慮運算能力與分散式架構。

3. 模型解釋性需求

解釋性類型	代表模型	特點與應用場景
高解釋性模型	線性迴歸、邏輯迴歸、淺層決策樹	結構簡單、邏輯清晰，便於溝通與審查，適用醫療、金融、法規監管。
低解釋性模型	隨機森林、深度神經網路	預測能力強但決策過程不直觀，建議搭配SHAP、LIME、偏倚圖等解釋工具提升透明度。

4. 運算資源與部署限制

資源狀況	選擇模型與策略
資源受限	選擇結構簡單、參數少、推論快的模型，如簡單決策樹、邏輯迴歸、小型神經網路，並可用剪枝、量化技術。
資源充足	可用高效能深度模型與模型集成，支援複雜前後處理流程。
即時推論需求	注重推論延遲與效能，搭配caching、模型蒸餾 (knowledge distillation) 等技術。

5. 偏差-變異權衡 (Bias-Variance Tradeoff)

名稱	定義	影響與特性
偏差 (Bias)	模型擬合能力不足，資料主要來自系統性誤差高 (欠擬合)	偏差高則模型簡單，穩定但表現欠佳。
變異 (Variance)	模型對訓練數據過度敏感，泛化能力差 (過擬合)	變異高則模型複雜，能擬合複雜模式，但不穩定。
模型複雜度	偏差	變異
低複雜度模型	高	低
高複雜度模型	低	高

模型訓練、評估與驗證

1. 資料分割與準備

資料集	用途
訓練集	用於模型參數學習與調整
驗證集	用於超參數調整與監控模型泛化能力
測試集	模型訓練完成後最終效能評估，模擬實際部署環境

• **K-fold 交叉驗證**：將資料分成K個子集，反覆輪流做訓練與驗證，提高評估穩定性及可信度。

2. 批次訓練設計與更新策略

訓練方式	特點與適用情況
全量訓練 (Batch Gradient Descent)	使用全部資料計算梯度，收斂路徑平滑，但記憶體需求高、不適合大規模資料

訓練方式	特點與適用情況
隨機梯度下降 (SGD)	每次用一筆樣本更新，適合線上學習與資料流，更新效率高，收斂不穩。
小批次訓練 (Mini-batch SGD)	固定筆數樣本更新，兼顧穩定性與效率，深度學習中最常用。大小需考慮GPU記憶體與任務特性。

3. 學習率調整策略

方法	說明
固定學習率	設定單一值，簡單任務適用，後期收斂可能停滯。
遞減學習率	定期降低學習率 (Step Decay / Exponential Decay)，幫助穩定收斂。
動態調整	如ReduceLROnPlateau，驗證效能停滯時自動降低學習率。
預熱策略	初期使用較低學習率逐漸升高，避免梯度爆炸，常見於Transformer類模型。

4. 早停策略與訓練終止準則

• **Early Stopping**：監控驗證集效能，當效能連續N次迭代無明顯提升 (容忍次數Patience) 或改善幅度低於閾值 (Minimum Delta) 時終止訓練。

• 配合學習率調整使用，提升模型穩定性與泛化能力。

5. 訓練過程監控與記錄

監控項目	工具與說明
訓練指標視覺化	TensorBoard、WandB、MLFlow，監控損失曲線與指標趨勢
超參數與模型版本管理	記錄超參數設定、模型結構與權重版本，方便複製與回溯
資源使用狀況	GPU、CPU、記憶體使用率追蹤，評估效能瓶頸與部署可行性

模型評估指標與效果衡量

(1) 分類任務評估指標

指標	公式	定義與適用情境	限制與說明
準確率 (Accuracy)	$\frac{TP + TN}{TP + FN + FP + TN}$	正確預測樣本佔比，類別均衡適用	類別不平衡時易誤導，如95%為負類資料時全預測負類仍達95%。
精確率 (Precision)	$\frac{TP}{TP + FP}$	預測為正類中實際正類比例，適用誤報代價高場景 (垃圾郵件、醫療診斷)	衡量預測正類的可信度。
召回率 (Recall)	$\frac{TP}{TP + FN}$	預測為正類中被正確預測比例，適用漏報代價高場景 (癌症偵測、詐騙)	衡量模型能抓住多少實際正類。
F1分數 (F1-Score)	$2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$	精確率與召回率的調和平均，不平衡且需兩者時適用	綜合評價精確率與召回率的表現。
ROC曲線與AUC	- ROC軸為假正率，縱軸為真正率。AUC為曲線下面積，值越接近1越好。	反映模型不同分類閾值的整體區分能力，適合調整分類閾值的應用	AUC越高，模型對正負類區分越好。

(2) 迴歸任務評估指標

指標	公式	定義與特點	適用情境與說明
均方誤差 (MSE)	$MSE = \frac{1}{n} \sum_{i=1}^n y_i^2$	預測誤差的平方平均，對大誤差敏感，極端值影響大。	強調大懲罰的任務，如金融風險預測、製程品質監控。
平均絕對誤差 (MAE)	$MAE = \frac{1}{n} \sum_{i=1}^n y_i $	預測誤差的絕對值平均，對異常值不敏感，估計穩定。	資料包含極端值時適用。
均方根誤差 (RMSE)	$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n y_i^2}$	MSE的平方根，回歸原始單位，保有MSE懲罰特性。	作為模型精度衡量的標準，廣泛用於報告與比較。
決定係數 (R ² Score)	$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$	衡量的變異解釋能力，分分子為殘差平方和，分母為總變異平方和。RSS，用於線性迴歸，適合非或未經標準化比較。	R ² = 1 完全解釋資料；R ² = 0 等同常數模型；R ² < 0 模型表現差於常數模型。適用於線性迴歸，適合非或未經標準化比較。

(3) 模型比較與綜合評估策略

評估模型不應只依賴單一指標，應根據任務特性組合多項指標進行多角度觀察，兼顧準確性、穩定性與風險控制。

任務類型	建議指標組合
分類任務	準確率、F1分數、ROC-AUC、混淆矩陣等指標綜合使用
迴歸任務	MSE、MAE、RMSE、R ² 等指標並用，根據誤差敏感度與解釋需求選擇適合指標

以上涵蓋了本次講座中關於資料增強、特徵工程、模型選擇、訓練策略與評估指標的完整內容，確保學生能深入掌握機器學習建模與參數調校的核心知識。

🔍 類別不平衡處理與評估策略

面對高度不平衡資料（如欺詐偵測、醫療診斷），傳統準確率常導致誤判，需搭配資料處理技術與適合的評估指標。

技術名稱	定義與說明	適用範圍	特點與優勢
類別重加權 (Class Weights)	在模型訓練時對少數類別賦予更高權重，透過損失函數加權自動調整學習焦點。	邏輯迴歸、神經網路	強化模型對少數類別的學習能力。
過採樣 (如 SMOTE)	Synthetic Minority Over-sampling Technique，透過合成新樣本平衡資料分佈，保留原始樣本空間結構，降低過擬合風險。	少數類別資料量不足的情況	增加少數類別樣本數，避免重複模型導致過擬合。
異常值建模 (Isolation Forest, One-Class SVM)	將不平衡問題視為異常值偵測，建構二分類行為模型，再將樣本。	極端不平衡資料，如欺詐偵測、設備故障預測	適合極端不平衡資料，聚異異常樣本識別。

• **迴歸任務評估：**可綜合使用MAE（平均絕對誤差）、RMSE（均方根誤差）與R²（決定係數）來觀察誤差分佈與模型擬合能力。

- **業務導向自定義指標：**
 - 風險導向任務（如醫療）：可設計誤判成本矩陣，強化高代價錯誤（如漏診）懲罰。

- **商業任務（如推薦系統、行銷）：**使用 NDCG (Normalized Discounted Cumulative Gain)、Profit Score等領域專屬指標。

🔄 交叉驗證（Cross-Validation）

交叉驗證是一種重要的模型評估技術，透過多次資料切分與訓練測試，真實衡量模型泛化能力及其穩定性。

方法	過程說明	特點	適用場景
K-fold	將資料均分為K份，輪流使用其中1份為驗證集，其餘為訓練集，重複K次並計算平均效能。	減少資料切片偶然性，廣泛適用；計算成本為K倍；常用K = 5或10。	中大型資料集，迴歸與分類泛化能力驗證。
Stratified K-fold	依類別比例分層抽樣，確保每一折中類別比例與整體相符，特別適用類別不平衡的分類問題。	解決類別比例導致的評估失真，提高模型穩定性。	欠平衡分類問題，如欺騙偵測、醫療診斷。
LOOCV (Leave-One-Out)	每次留下1筆資料當驗證集，其餘n - 1筆訓練，重複n次。	偏差最小，總合珍貴資料成本最高，對訓練集微小變動敏感。	樣本極小但珍貴資料，如珍貴病例研究資料。
Repeated K-fold	在標準K-fold基礎上多次隨機重分組，計算多組結果平均與變異數，提升模型穩定性觀察。	評估結果更穩定，能觀察表現波動與可信區間；計算成本更高。	模型調參與效能穩定性評估、金融風險、醫療高重現性場景。

• **穩定性視覺化：**利用箱型圖 (Boxplot)、平均排名圖 (Mean Rank Plot) 觀察模型多輪驗證中的表現分佈與變異。

🔧 模型調整與優化

模型調整與效能優化是機器學習由實驗走向實務的關鍵階段，針對效能不穩、過擬合、推論延遲及資源消耗等問題，進行系統化優化。

核心面向	說明
超參數調校 (Hyperparameter Tuning)	調整非學習參數以達最佳效能。
正則化技術 (Regularization)	減少過擬合，提升泛化能力。
資料增強與重取樣 (Data Augmentation & Resampling)	增加訓練資料多樣性與平衡性，改善模型穩定度。
模型壓縮與加速 (Model Compression & Acceleration)	降低模型大小與推論時間，便於部署於終端或邊緣裝置。

🎯 超參數調校

1. 學習率 (Learning Rate)

控制模型每次反向傳播後參數更新幅度的超參數，對收斂效率、模型穩定性及最終效能影響巨大。

內容	說明
定義	學習率由訓練者指定，非模型自動調整。
適用範圍	梯度下降及其變形演算法（如Mini-Batch SGD、Momentum、Adam），深度學習架構（CNN、RNN、Transformer）。

內容	說明
機制	- 學習率大：快速接近最小值，易震盪或發散。但學習率小：收斂慢且穩定度低。 - 實務常用學習率退火 (Annealing) 或調度器 (Scheduler)。
常見問題	過高導致梯度爆炸及震盪，過低收斂緩慢，固定學習率兼顧不同訓練階段需求。

2. 批次大小 (Batch Size)

每次參與梯度更新的訓練樣本數，影響梯度估計穩定性與訓練效率。

內容	說明
適用範圍	主要用於深度學習模型訓練，尤其使用GPU加速時。
機制	- 小批次：提供較高隨機性，有助跳脫局部極小值，但梯度波動大，訓練不穩定。 - 大批次：梯度估計穩定，加速收斂，可能降低泛化能力。
常見問題	批次過小導致震盪劇烈、訓練時間長；批次過大降低泛化能力且易陷入局部最小值；未考慮硬體限制影響訓練失敗。
與學習率關係	批次大小與學習率高度耦合，批次放大需調整學習率。

3. 網路深度與寬度 (Network Depth & Width)

參數	定義	適用範圍	作用機制	常見問題
網路深度	神經網路層數 (輸入層、隱藏層、輸出層)	深度學習模型 (MLP、CNN、RNN、Transformer)	增加深度提升非線性表達能力，處理複雜模式辨識。	過深易梯度消失，須搭配初始化、Batch Normalization、殘差連接。
網路寬度	每層神經元數 (或通道、單元數)	同上	增加寬度提供豐富特徵空間，捕捉多樣化輸入資訊。	過寬易過適合，過淺則欠拟合，無法學習複雜特徵。

4. 激活函數 (Activation Function)

神經元加權輸入轉換為輸出的非線性函數，賦予神經網路處理非線性問題能力。

函數名稱	公式	適用範圍	特點與說明
Softmax	$\text{Softmax}(z_j) = \frac{e^{z_j}}{\sum_{j=1}^C e^{z_j}}$	多類別單選分類輸出層	輸出機率分佈，總和為1，確保類別間相互排斥。
ReLU	$\text{ReLU}(x) = \max(0, x)$	深度神經網路隱藏層	計算簡單快速，解決梯度消失，輸出無固定範圍。
Sigmoid	$\sigma(x) = \frac{1}{1+e^{-x}}$	二元分類輸出層	輸出表示0到1之間機率，但不保證輸出總和為1。
Tanh	$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	深度神經網路隱藏層	輸出範圍為-1到1，產生中心對稱效果，梯度較大，可加速學習。

5. 優化器 (Optimizer)

負責更新模型參數以最小化損失函數的演算法，影響收斂速度、穩定性與最終表現。

優化器名稱	定義與公式	適用範圍	特點與常見問題
SGD	隨機梯度下降： $\theta_{t+1} = \theta_t - \eta \cdot \nabla_{\theta} L(\theta_t)$ 每次用一筆或小批資料計算梯度。	小型模型、淺層神經網路、記憶體有限環境	計算簡單，更新頻繁，易受噪聲影響，依賴學習率設定。
Momentum	在SGD基礎上累積過去梯度產生慣性： $v_{t+1} = \gamma \cdot v_t + \eta \cdot \nabla_{\theta} L(\theta_t)$ $\theta_{t+1} = \theta_t - v_{t+1}$ γ 為動量係數。	深度神經網路，梯度震盪大，需加快收斂	減少震盪，幫助跳脫局部極小值，收斂快，需調整動量係數。
Adagrad	自動調整每參數學習率： $G_t = G_{t-1} + (\nabla_{\theta} L(\theta_t))^2$ $\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{G_t}} \cdot \nabla_{\theta} L(\theta_t)$ 適合稀疏特徵。	稀疏特徵場景，如文本、NLP	為每參數分學習率，適合稀疏特點是學習率減速，可停止學習。

優化器名稱	定義與公式	適用範圍	特點與常見問題
Adam	結合 Momentum 與 RMSprop，計算一階動量 m_t 與二階動量 v_t 並修正偏差，更新參數： $m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla_{\theta} L(\theta_t)$ $v_t = \beta_2 v_{t-1} + (1 - \beta_2) (\nabla_{\theta} L(\theta_t))^2$ 偏差修正： $\hat{m}_t = \frac{m_t}{1 - \beta_1^t}$ $\hat{v}_t = \frac{v_t}{1 - \beta_2^t}$ $\theta_t = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t + \epsilon}}$	幾乎所有深度學習模型	收斂快且穩定，自動調整學習率，記憶體需求較高；泛化能力部分情況略遜 SGD。

6. 正則化係數 (Regularization Coefficient)

| 控制模型複雜度的超參數，避免過擬合。

- 正則化項加入損失函數：

$Loss = \text{原始損失} + \lambda \times \text{Regularization Term}$

其中 λ 為正則化係數。

作用機制	效果
λ 增大	強化限制，權重壓縮更小，模型簡單化，可能導致欠擬合。
適用範圍	線性迴歸、邏輯迴歸、SVM、Lasso迴歸、Ridge迴歸，及深度學習神經網路 (CNN、RNN、Transformer)。

以上筆記涵蓋本次講義內容的重點，包含類別不平衡處理技術、交叉驗證方法、模型優化核心超參數調校，及其作用機制與常見問題，完整掌握這些知識將有助於應對機器學習建模與調參實務挑戰。

🔗 正則化技術與模型穩定化

過擬合 (Overfitting) 與正則化目的

過擬合指模型過度擬合訓練資料的細節，導致在新資料上表現不佳。

正則化技術 (Regularization) 用於限制模型複雜度，提升泛化能力，避免過擬合。

1. L1 正則化 (Lasso)

項目	說明	
定義	在損失函數中加入所有參數絕對值總和，即 $Loss = \text{原始損失} + \lambda \sum \theta_i $	
作用	促使部分權重變為零，自動執行特徵選擇，使模型更簡化。	
應用場景	高維度資料或多情況。	
風險	λ 過大可能導致重要特徵被刪除，造成欠擬合。	
名稱由來	Lasso = Least Absolute Shrinkage and Selection Operator	
	- Least Absolute：絕對值限制 (L1)	
	- Shrinkage：權重縮小	
	- Selection：權重為0，自動特徵選擇	

2. L2 正則化 (Ridge)

項目	說明
定義	在損失函數中加入所有權重平方和，即 $Loss = \text{原始損失} + \lambda \sum \theta_i^2$
作用	讓權重縮小但不為零，穩定權重大小，防止過擬合。
幾何意義	權重解空間在橢圓（橢球）形狀範圍內，類似「脊線 (Ridge)」分佈。
風險	λ 過大可能導致欠擬合。
名稱由來	「Ridge」來自統計中多重共線性問題下的脊線估計解。

3. Elastic Net

項目	說明
定義	結合 L1 與 L2 正則化，損失函數為
Loss =	原始損失 + $\lambda_1 \sum \theta_i + \lambda_2 \sum \theta_i^2$
特點	保留 L1 的特徵選擇能力，利用 L2 避免過度稀疏，適合多重共線性問題。
調參複雜度	需同時調整兩個正則化係數 λ_1 與 λ_2 。

4. Dropout

項目	說明
定義	訓練時隨機暫時關閉部分神經元，減少神經元間依賴，促進多路徑特徵學習。
公式示意：	$\text{output} = \text{dropout}(x, p)$ ，其中 p 是保留機率。
訓練階段	隨機將部分神經元輸出設為0，學習不同子網路結構。
測試階段	不丟棄神經元，權重按比例縮放，保持輸出期望一致。
特點	降低過擬合，無需修改網路架構，主要用於深度神經網路。
風險	Dropout率過高可能導致學習效果不佳，測試時需關閉並調整權重。

5. Early Stopping（早停法）

項目	說明
定義	在訓練中若驗證集損失連續多次迭代無改善，提前停止訓練。
參數	使用 patience 控制允許多少次不進步。
作用	防止過擬合，節省訓練時間，無需改變模型架構。
風險	patience 過短易欠擬合，過長仍可能過擬合。

📊 資料增強與重取樣

項目	說明
定義	利用隨機變換方法，人工擴增訓練資料，提升模型泛化能力。
影像方法	旋轉、平移、翻轉、縮放、裁切、添加雜訊、調整亮度等。
文字方法	同義字替換、隨機刪詞、分詞打亂、句子順序調整等。
音訊方法	改變播放速度、音量調整、加背景噪音、隨機靜音片段等。
優點	增加資料多樣性，降低過擬合，提升泛化能力，無需額外收集昂貴資料。
風險	不當變換可能改變語意或標註，增加計算成本，需依場景謹慎選擇手法。

🔄 重取樣 (Resampling)

方法	原理	優點	缺點
過採樣 (Oversampling)	增加少數類別樣本數，如複製或使用 SMOTE 合成新樣本。	平衡類別分佈，提升預測能力，不損失原始資料。	複製易過擬合，合成樣本可能不自然。
欠採樣 (Undersampling)	減少多數類別樣本數，達成類別平衡。	降低計算成本，簡單快速。	可能丟失重要資料，少數類別稀少時不適用。
類別權重調整 (Class Weighting)	透過損失函數賦予少數類別更高權重，提高模型對少數類別重視。	保留資料完整性，適用資料有限或生成新樣本無法生成新資料，計算資源較低。	權重調整需謹慎，過大可能影響效果。

⚡ 模型壓縮與加速技術

1. 知識蒸餾 (Knowledge Distillation)

項目	說明
定義	將大型教師模型知識轉移給較小學生模型，使其能接近教師模型的表現。
應用場景	部署於硬體資源有限的裝置（行動裝置、邊緣運算節點）。
優點	學生模型體積小，推論快，適合模型壓縮與加速。
風險	需額外訓練時間與計算資源，教師模型偽像會被傳遞。

2. 模型剪枝 (Pruning)

項目	說明
定義	移除貢獻小的權重或神經元需求。
類型	結構化剪枝：移除整個神經元或層級，易與硬體加速器整合。
非結構化剪枝：移除零散權重，模型稀疏化，硬體支援較差。	
優點	減少參數數量，提升運算效率，降低延遲，可與其他技術結合。
風險	過度剪枝致準確度下降，非結構化剪枝硬體支援有限。

3. 量化 (Quantization)

項目	說明
定義	將高精度參數（如32-bit浮點數）轉為低精度格式（如8-bit 整數），減少模型大小與加速運算。
優點	降低儲存空間與記憶體需求，減少運算負擔，適用硬體加速器。
風險	直接量化可能損失準確度，需量化感知訓練 (Quantization Aware Training, QAT) 適應誤差。

4. 混合精度訓練 (Mixed Precision Training)

項目	說明
定義	於訓練時同時使用不同數值精度（如FP16與FP32），兼顧速度與精度。

項目	說明
優點	加速訓練，減少記憶體占用，支持更大批次及深層模型。
風險	需硬體支援，低精度可能帶來數值不穩定，需處理梯度縮放等問題。

重要習題解析

題號	題目重點	答案	解析重點
1	缺失值補值方法中使用模型進行補值	(C)	預測模型填補利用其他特徵訓練模型，捕捉數據間聯性較優。
2	利用統計分佈判斷異常值方法	(B)	四分位距法(IQR)根據Q1、Q3判定異常點，適合數值型資料。
3	訓練過程中同步進行特徵選擇方法	(C)	Embedded方法如Lasso、Ridge透過正則化直接控制權重。
4	右偏分佈常用轉換降低偏態	(B)	對數轉換(Log Transform)能有效降低極端值影響。
5	訓練集表現佳測試差為何問題？	(C)	過擬合，學習過頭訓練資料細節，泛化能力不足。
6	留一法交叉驗證 (LOOCV)	(C)	每次留一筆驗證，最大化資料利用但計算成本高。
7	隨機關閉神經元減少過擬合技術	(B)	Dropout，迫使模型學習更多種子網路，降低依賴。
8	知識蒸餾主要目的	(C)	將大型教師模型知識轉移給小型學生模型，保持效果並縮小模型。
9	自動調整學習率適用稀疏資料優化	(B)	Adagrad，根據參數更新頻率自動調整學習率。
10	One-hot Encoding造成運算負擔原因	(C)	類別變數高維數導致特徵維度爆炸，增加計算負擔。

資料管理與分類的

「資料管理的嚴謹性在於清楚知道資料存放位置、保存期限，並依據資料特性進行層級分類，以有效控管風險。」

項目	內容說明
儲存位置	內部伺服器、雲端平台、第三方服務商等
保留期限	資料保存時間長短及超期刪除、匿名化)
開放層級	公開資料：對外公開、無涉個資（如政府統計資料、年報等） 非公開資料：限內部使用，需特定權限存取
敏感度層級	一般資料：無個資或機敏業務，風險低 機密資料：商業秘密、內部策略、外洩影響營運 個人資料：含可識別個人資訊，受個資法規嚴格管理 高度敏感個資：健康、財務、宗教、政治傾向等，法律規範更嚴

隱私影響評估 (Privacy Impact Assessment, PIA)

「PIA是系統性分析資料處理對個人隱私影響的工具，並提出風險緩解策略，是降低隱私風險的重要實務。」

PIA執行五步驟

步驟	說明
資料流程盤點	釐清資料從收集、處理、儲存、使用到刪除的完整流程
風險辨識	分析資料流程中可能對個人隱私造成風險的環節
影響程度分析	評估風險發生後對個人權益或組織法律、營運、信譽的影響
策略擬定	制定技術與管理防範措施，降低風險發生率與衝擊程度
治理責任分工	明確各部門與角色在隱私保護中的責任與權限

風險矩陣與風險等級

「風險矩陣結合風險發生的可能性與影響程度，協助企業視覺化並優先處理高風險區域。」

風險要素	說明
風險發生機率	風險發生的可能性，如低 (Rare)、中 (Possible)、高 (Likely)
風險影響程度	風險發生後對業務或系統的衝擊強度，如輕微 (Minor)、重大 (Major)、災難性 (Critical)
風險等級計算	風險等級 = 發生機率 × 影響程度
風險等級分類	低風險 (Low Risk)：可接受自主監控 中風險 (Medium Risk)：需規劃因應對策 高風險 (High Risk)：應優先處理，必要時迴避或延後導入

再識別模擬與滲透測試 (Re-identification Simulation)

「企業應透過再識別模擬與滲透測試，驗證資料匿名化或去識別化措施的有效性，防範個人身份被還原。」

常見測試方法

方法	說明
交叉比對測試	利用公開社群資料、政府開放資料或商業數據嘗試還原匿名個體身分
欄位組合分析	評估多欄位組合是否具備足夠推導能力辨識個人身份

若風險偏高須採取之對策

- 強化匿名化或去識別化技術（如增加數據模糊度、降低數據精細度）
- 調整資料釋出範圍或限制使用情境
- 審慎評估是否適合公開資料集

隱私保護與匿名化技術實務應用 (一) 基礎資料匿名化技術

技術	定義	應用場景	優點	限制
遮蔽 (Masking)	用符號或虛構數據替換敏感欄位部分或全部，如「王大明」改為「王○○」	報表展示、安全測試	實作簡單，保留資料格式	僅隱藏部分資料，其他欄位仍可辨識
雜湊處理 (Hashing)	對身分類欄位如帳號、Email進行單向雜湊 (如SHA-256)，產生不可逆字串用於比對	匿名用戶ID、跨資料庫比對	不可逆，支援一致性，安全性高	原始值被隱藏，不適合有彩虹表攻擊的數值分析
泛化 (Generalization)	降低資料精度，如將「1987-03-12」泛化為「1980年代」，「台北市」簡化為「北市」	公開數據庫、統計分析	簡單有效，保留分佈特性	精度降低，影響分析準確度
分桶 (Bucketing)	將連續數值轉換為區間，如收入「\$8,000」變為「\$50K-60K」，年齡「32」歸類為「30-39歲」區間	統計報告、人口分析	保留趨勢，降低識別風險	分桶過細仍有再識別風險
隨機擾動 (Noise Injection)	在數值資料中加入隨機噪聲（如高斯、拉普拉斯、數值擾動），數據雜以精準推算	數值資料分享、統計分析	保留統計特性，標準差可控	噪聲設計，需平衡保護效果與數據準確性

(2) 進階隱私強化技術 (Privacy-Enhancing Technologies, PETs)

技術	定義與特性	應用場景	優點	限制
K-匿名 (K-Anonymity)	每筆紀錄至少與K-1筆在準識別欄位相同，降低個體識別風險	公開數據集、醫療研究、金融分析	結構化資料保護佳，易實施	計算複雜，K值高時資料精度損失大
L-多樣性 (L-Diversity)	群組內敏感欄位有至少L種不同值，避免屬性推測	同上	強化屬性保護	同上
T-接近性 (T-Closeness)	群組內敏感欄位分佈與整體分佈資料相近，防止個體特徵推測	同上	防止分佈偏差推測	同上
聯邦學習 (Federated Learning)	模型在各本地端訓練，僅傳送參數至中央伺服器聚合，避免原始資料傳輸	醫療聯盟、手機鍵盤預測	保留資料本地性，降低洩漏風險	通訊成本，可能逆推風險
同態加密 (Homomorphic Encryption)	允許在加密資料上直接運算，解密後結果與對明文運算結果相同，資料全程加密	雲端AI訓練、金融、醫療、政府外包運算	數據外包保護，無需解密，安全	計算效能低，同態加密硬體支援需求高

合規實務建議

項目	內容
合法來源與告知同意	確認資料來源合法且同意必須具備自願性、明確性、具體性、可撤回性，若無同意則需其他合法依據（契約、法定義務等）
資料最小化與目的限制	僅收集AI訓練所需最低限度資料，避免未告知或未同意的用途，敏感資料需評估必要性並尋求替代方式（如泛化統計資料）

項目	內容
去識別化或匿名化處理	對外共享需優先去識別化/匿名化，確保無法追溯到個人身份並符合資訊保護法規要求，建立元數據記錄法規，保留風險評估紀錄
透明度與紀錄保存	建立完善資料處理紀錄（來源、法律基礎、處理過程、共享情況、受影響資料類別、保護技術、風險措施），保持對外透明，定期稽核政策檢視
跨境傳輸規範	涉及跨國資料流通須符合各國資料傳輸限制，如GDPR要求足夠保護措施，明確跨境流動範圍與用途，評估接收國隱私水準，制定協議並保存紀錄

演算法偏見與公平性

1. 偏見的成因與類型

類別	說明	例子與影響
資料代表性與偏誤風險	訓練資料無法全面反映目標族群意見，影響模型公平性與可靠性	醫療模型缺少特定年齡層資料，信用審核有種族歧視，語料庫限於北美語境
資料偏見三類	來源偏誤：資料蒐集不均，含歧視性標籤；處理偏誤：資料清洗過程忽略敏感特徵；目標偏誤：模型目標設定放大資料中某些群體偏見	群體分佈不均、個別化標籤、標籤性偏見分析差異
模型偏見與歧視	推薦系統忽略少數群體喜好，目標函數權重少數群體特徵，正規化降低少數群體特徵敏感度	

2. 偏見的潛在影響

影響範圍	說明
弱勢群體受歧視	女性、少數族群、高齡者、身心障礙者、低收入家庭、金融服務、醫療診斷等
企業品牌與信譽受損	違反反歧視法、個人資料保護法，可能遭罰款、訴訟或監管處分

公平性指標與評估工具

(1) 常見公平性指標

指標名稱	定義	適用情境	限制
Demographic Parity (群體平等率)	不同群體獲得正面預測比例大致相同，強調結果均等分配 (Equality of Outcome)	招聘、入學等要求高場合	犧牲個案預判準確性，無法考量實際資格差異
Equal Opportunity (機會平等)	實際應得正面預測比例與群體中體被正確率相等，強調過程公平，不被偏見左右	醫療診斷、社會福利核准等	僅關注正面預測，忽略負例錯誤比例
Equalized Odds (均衡機率)	模型對正面與負面預測的準確率均相同，強調過程公平	司法判決、信用評估等敏感領域	實務難達成，需犧牲部分整體效能，實現複雜
Disparate Impact (不利影響比)	比較群體間正面預測結果比率，若某群體正面預測比例顯著低於其他群體，即可能視為間接歧視	法律合規審查，如招聘與貸款	僅反映比例差異，無法追溯偏見來源

(2) 公平性評估工具

工具名稱	功能與特性	優點	限制
IBM AI Fairness 360 (AIF360)	支援70多種公平性指標，提供前置處理、後處理方法，產生公平化報告	指標齊全，文件完整，適合研究與企業試驗應用	大型商業模型需額外整合與測試
Microsoft Fairlearn	衡量及降低AI公平性問題，支援後處理、再訓練、模型解釋性分析	與Python生態系統相容，易整合現有流程	去偏功能較少，適合中小型項目

降低演算法偏見的方法論與技術方案

(1) 資料前處理

方法名稱	定義與說明	實例
資料重新抽樣 (Re-sampling)	增減特定群體資料數量使分佈均衡	招聘模型調整不同性別履歷數量達成平衡
特徵去偏處理 (Feature Neutralization)	內容未完整提供，留待後續講解	無

AI 公平性治理策略與技術

一、資料層面偏見修正方法

方法	定義	實例
敏感特徵移除	移除或調整可能引發偏見的敏感特徵 (如性別、種族、或高度相關特徵)	銀行信用評分移除客戶族裔特徵，避免種族偏見
資料匿名化與泛化	降低敏感特徵的精確度，如將生年轉換為年齡區間，減少偏見	將特定族群改為泛化標籤

敏感特徵移除與資料匿名化都是為了降低模型基於敏感資訊的偏見風險，其中泛化是透過降低資料精度達成。

二、模型內部處理方法

方法	定義	實例
公平性約束訓練	訓練時加入公平性指標 (如Demographic Parity、Equal Opportunity) 作為約束條件	貸款模型強制不同性別核准率相似
對抗式去偏模型	同時訓練對抗式網路，迫使主模型學到不受敏感特徵影響的特徵表現	招聘模型透過對抗網路，使履歷分析結果無法判斷申請者性別
公平性正規化	在目標函數加入公平性損失項，平衡準確度與公平性	信用評分模型加入公平性損失，確保不同族群得分接近

對抗式去偏模型是一種透過對抗網路強制模型忽略敏感特徵的技術，提升公平性。

三、模型後處理方法

方法	定義	實例
結果門檻調整	模型預測分數後，針對不同群體調整正向預測閾值，改變判斷標準 (閾值) 以達公平性	司法判決風險評估模型調整不同族群的判斷閾值
結果校準	不改變閾值，重新校準不同群體的預測分數，使相同分數在各群體間意義相同	信用評分模型在男女族裔間校準分數，避免待遇差異

結果門檻調整是直接改變決策閾值，而結果校準則是調整分數解釋，兩者皆屬於模型輸出層面的公平性調整。

組織面向的AI公平性治理策略

1. 建立AI公平性治理機制

具體作法	說明
建立公平性政策與標準	制定明確的公平性原則與指標 (如Demographic Parity、Equal Opportunity)，並設定可接受範圍
設立跨部門公平性審查委員會	包含法務、技術、產品、倫理、風險管理等部門，負責早期參與與定期審查AI系統公平性
明確責任與問責機制	將公平性納入高階主管KPI與企業ESG報告，建立審查追溯紀錄，確保透明及可追溯

跨部門委員會是企業治理AI公平的重要組織架構，確保多面向審視並防範偏見。

2. 多元化團隊與公平意識教育訓練

具體作法	說明
招募多元化團隊成員	聘用不同性別、族群、文化與專業背景的人才，降低團隊盲點
推動公平性與倫理培訓	定期舉辦課程，提升員工對偏見成因及風險的認識，建立公平性文化

多元團隊與教育訓練是減少演算法偏見的重要基礎，促進對公平性的敏感度。

3. 公平性評估與稽核制度

具體作法	說明
定期公平性稽核	每年對關鍵AI系統進行公平性審查與報告，新系統與重大更新亦須審查
導入公平性指標監控系統	將公平性指標納入日常監控，建立即時警報機制，超出預設範圍時啟動應變措施

持續的稽核與監控是確保AI系統長期公平運作的關鍵。

4. AI公平性資訊揭露與溝通策略

具體作法	說明
主動揭露公平性報告	定期公開公平性指標、偏見情形及改善措施，彰顯企業責任感
引入第三方獨立驗證	邀請外部機構進行審核並公開結果，提升信任度與公信力
與利益關係人溝通	聆聽不同群體與社會大眾意見，持續改進AI系統

透明度與溝通是建立外界信任與促進AI公平性的重要策略。

重要名詞解釋

名詞	解釋
Demographic Parity (人口統計平等)	不同群體間正向預測概率相等
Equal Opportunity (平等機會)	對真正應被選中的個體，不同群體有同等被正確預測的機率
對抗式去偏模型 (Adversarial Fairness)	利用對抗網路迫使主模型不依賴敏感特徵，達成公平性
結果門檻調整 (Threshold Adjustment)	調整不同群體的決策閾值以達到公平性
結果校準 (Calibration)	重新校準預測分數，使不同群體分數具有同等意義

常見AI公平性選擇題解析摘要

題號	正確答案	解析重點
1	(C)	姓名、電子郵件、身分證號為直接識別個資 (PII)。
2	(B)	將薪資加入隨機誤差屬於隨機擾動技術，強化匿名化。
3	(B)	調整不同群體模型預測閾值為結果門檻調整，屬模型後處理。
4	(A)	Equal Opportunity強調真正應被選中者的平等正確預測機率。
5	(A)	對抗式去偏模型用於降低敏感特徵影響。

題號	正確答案	解析重點
6	(C)	類別重加權提升少數群體辨識能力，解決樣本不均問題。
7	(A)	1-接近性降低機率分布差異導致的識別風險。

題號	正確答案	解析重點
8	(C)	公平性審查委員會負責跨部門AI公平性治理。
9	(A)	SMOTE用於合成少數類別樣本，減少過擬合。

題號	正確答案	解析重點
10	(C)	知識蒸餾非隱私保護技術，常見隱私技術為遮蔽、泛化與分桶。

 **重要補充**
| 隱私保護基礎技術範例

遮蔽 (Masking)：以星號等符號遮蓋敏感資料。
泛化 (Generalization)：將具體數值轉換為較模糊的區間或類別。
分桶 (Bucketing)：將連續數據分組，降低辨識風險。
資料偏見來源之一
群體樣本數不均，導致模型偏好多數群體，需透過類別重加權或資料增強技術如SMOTE調整。